Московский государственный технический университет им. Н.Э. Баумана
Факультет «Информатика и системы управления»
Кафедра «Автоматизированные системы обработки информации и управления»

"Методы машинного обучения"

Отчет по лабораторной работе №5

"Линейные модели, SVM и деревья решений"

Выполнил:

Буклин С.В.

Группа ИУ5-21м

Лабораторная работа №5

Цель: изучение линейных моделей, SVM и деревьев решений.

Задание

- 1. Выберите набор данных (датасет) для решения задачи классификации или регресии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите 1) одну из линейных моделей, 2) SVM и 3) дерево решений. Оцените качество моделей с помощью трех подходящих для задачи метрик. Сравните качество полученных моделей.
- 5. Произведите для каждой модели подбор одного гиперпараметра с использованием GridSearchCV и кроссвалидации.
- 6. Повторите пункт 4 для найденных оптимальных значений гиперпараметров. Сравните качество полученных моделей с качеством моделей, полученных в пункте 4.

Ход выполнения лабораторной работы

Выбор датасета

В качестве исходных данных выбираем датасет Heart Disease UCI (https://www.kaggle.com/ronitf/heart-disease-uci). 303 записи, 14 признаков, целевой признак относится к наличию болезни сердца у пациента: 0 - нет болезни сердца, 1 - есть.

In [0]:

from google.colab import drive, files
drive.mount('/content/drive')

Go to this URL in a browser: https://accounts.google.com/o/oauth2/auth?client_id=947318989803-6 bn6qk8qdgf4n4g3pfee6491hc0brc4i.apps.googleusercontent.com&redirect_uri=urn%3Aietf%3Awg%3Aoauth%3A2.0%3Aoob&scope=email%20https%3A%2F%2Fwww.googleapis.com%2Fauth%2Fdocs.test%20https%3A%2F%2Fwww.googleapis.com%2Fauth%2Fdrive.photos.readonly%20https%3A%2F%2Fwww.googleapis.com%2Fauth%2Fdrive.photos.readonly%20https%3A%2F%2Fwww.googleapis.com%2Fauth%2Fdrive.photos.readonly%20https%3A%2F%2Fwww.googleapis.com%2Fauth%2Fpeopleapi.readonly&response_type=code

Enter your authorization code:
.........
Mounted at /content/drive

```
In [0]:
```

```
from google.colab import files
import os
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
os.listdir()
data = pd.read_csv('drive/My Drive/mmo_datasets/heart.csv',
                   sep=",", encoding="iso-8859-1")
```

In [0]:

```
total count = data.shape[0]
num cols = []
for col in data.columns:
   # Количество пустых значений
   temp null count = data[data[col].isnull()].shape[0]
   dt = str(data[col].dtype)
   if temp null count>0:
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'
              .format(col, dt, temp_null_count, temp_perc))
data_cleared = data
```

In [0]:

```
uniquevalues = np.unique(data_cleared['target'].values)
uniquevalues
Out[0]:
```

array([0, 1])

train_test_split

In [0]:

```
target = data cleared['target']
data_cleared = data_cleared.drop('target', axis=1)
```

In [0]:

```
data_cleared.head(10)
```

Out[0]:

	age	sex	ср	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal
0	63	1	3	145	233	1	0	150	0	2.3	0	0	1
1	37	1	2	130	250	0	1	187	0	3.5	0	0	2
2	41	0	1	130	204	0	0	172	0	1.4	2	0	2
3	56	1	1	120	236	0	1	178	0	0.8	2	0	2
4	57	0	0	120	354	0	1	163	1	0.6	2	0	2
5	57	1	0	140	192	0	1	148	0	0.4	1	0	1
6	56	0	1	140	294	0	0	153	0	1.3	1	0	2
7	44	1	1	120	263	0	1	173	0	0.0	2	0	3
8	52	1	2	172	199	1	1	162	0	0.5	2	0	3
9	57	1	2	150	168	0	1	174	0	1.6	2	0	2

```
In [0]:

from sklearn.model_selection import train_test_split
X_train, X_test, Y_train, Y_test = train_test_split(
    data_cleared,
    target,
    test_size=0.2,
    random_state=1
)

In [0]:
```

```
X_train.shape, Y_train.shape
Out[0]:
((242, 13), (242,))
In [0]:

X_test.shape, Y_test.shape
Out[0]:
```

Обучение

((61, 13), (61,))

```
In [0]:
```

```
from sklearn.linear_model import SGDClassifier
from sklearn.svm import LinearSVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import GridSearchCV

from sklearn.metrics import accuracy_score
from sklearn.metrics import balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, fl_score
```

Стохастический градиентный спуск

```
In [0]:
```

```
sgd = SGDClassifier().fit(X_train, Y_train)
predicted_sgd = sgd.predict(X_test)
```

/usr/local/lib/python3.6/dist-packages/sklearn/linear_model/stochastic_gradient.py:166: FutureW arning: max_iter and tol parameters have been added in SGDClassifier in 0.19. If both are left unset, they default to max_iter=5 and tol=None. If tol is not None, max_iter defaults to max_it er=1000. From 0.21, default max_iter will be 1000, and default tol will be 1e-3. FutureWarning)

In [0]:

```
accuracy_score(Y_test, predicted_sgd)
```

Out[0]:

0.5081967213114754

```
In [0]:
balanced accuracy score(Y test, predicted sgd)
Out[0]:
0.5161290322580645
In [0]:
(precision_score(Y_test, predicted_sgd, average='weighted'),
recall score(Y test, predicted sgd, average='weighted'))
Out[0]:
(0.7540983606557377, 0.5081967213114754)
In [0]:
f1 score(Y test, predicted sgd, average='weighted')
Out[0]:
0.35963114754098363
Линейный классификатор на основе SVM
In [0]:
svm = LinearSVC(C=1.0).fit(X train, Y train)
predicted svm = svm.predict(X test)
/usr/local/lib/python3.6/dist-packages/sklearn/svm/base.py:931: ConvergenceWarning: Liblinear f
ailed to converge, increase the number of iterations.
  "the number of iterations.", ConvergenceWarning)
In [0]:
accuracy_score(Y_test, predicted_svm)
Out[0]:
0.7704918032786885
In [0]:
balanced_accuracy_score(Y_test, predicted_svm)
Out[0]:
0.7677419354838709
In [0]:
(precision score(Y test, predicted svm, average='weighted'),
recall_score(Y_test, predicted_svm, average='weighted'))
Out[0]:
(0.8020791683326669, 0.7704918032786885)
In [0]:
f1 score(Y test, predicted svm, average='weighted')
Out[0]:
0.7634790528233151
```

Дерево решений

```
In [0]:
dt = DecisionTreeClassifier(random state=1).fit(X train, Y train)
predicted dt = dt.predict(X test)
In [0]:
accuracy score(Y test, predicted dt)
Out[0]:
0.6885245901639344
In [0]:
balanced_accuracy_score(Y_test, predicted_dt)
Out[0]:
0.6887096774193548
In [0]:
(precision_score(Y_test, predicted_dt, average='weighted'),
recall_score(Y_test, predicted_dt, average='weighted'))
Out[0]:
(0.6888947646747752, 0.6885245901639344)
In [0]:
f1 score(Y test, predicted dt, average='weighted')
Out[0]:
0.6885245901639343
```

Из двух представленных моделей с параметрами по умолчанию с задачей классификации на выбранном датасете лучше справляется линейный классификатор на основе SVM.

Подбор гиперпараметров

Стохастический градиентный спуск

```
In [0]:
```

```
import warnings
warnings.filterwarnings('ignore')
clf_gs_sgd = GridSearchCV(SGDClassifier(), tuned_parameters, cv=5,
                      scoring='accuracy')
clf_gs_sgd.fit(X_train, Y_train)
Out[0]:
GridSearchCV(cv=5, error_score='raise-deprecating',
       estimator=SGDClassifier(alpha=0.0001, average=False, class_weight=None,
       early stopping=False, epsilon=0.1, eta0=0.0, fit intercept=True,
       l1_ratio=0.15, learning_rate='optimal', loss='hinge', max_iter=None,
       n_iter=None, n_iter_no_change=5, n_jobs=None, penalty='l2',
       power t=0.5, random state=None, shuffle=True, tol=None,
       validation_fraction=0.1, verbose=0, warm_start=False),
       fit_params=None, iid='warn', n_jobs=None,
       param_grid=[{'l1_ratio': array([0. , 0.05, 0.1 , 0.15, 0.2 , 0.25, 0.3 , 0.35, 0.4 , 0.
45, 0.5
       0.55, \ 0.6, \ 0.65, \ 0.7, \ 0.75, \ 0.8, \ 0.85, \ 0.9, \ 0.95])\}],
       pre_dispatch='2*n_jobs', refit=True, return_train_score='warn',
       scoring='accuracy', verbose=0)
```

In [0]:

```
clf_gs_sgd.best_params_
```

Out[0]:


{'l1_ratio': 0.8}

In [0]:

```
plt.plot(n_range, clf_gs_sgd.cv_results_['mean_test_score'])
```

Out[0]:

[<matplotlib.lines.Line2D at 0x7f3fe94ec048>]



Линейный классификатор на основе SVM

```
In [0]:
```

```
n_range = np.array(range(1,20,1))
tuned_parameters = [{'C': n_range}]
tuned_parameters
```

```
Out[0]:
```

```
[{'C': array([ 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19])}]
```

```
In [0]:
```

In [0]:

```
clf_gs_svm.best_params_
```

Out[0]:


{'C': 8}

In [0]:

```
plt.plot(n_range, clf_gs_svm.cv_results_['mean_test_score'])
```

Out[0]:

[<matplotlib.lines.Line2D at 0x7f3fe94c5dd8>]



Дерево решений


```
In [0]:
```

```
n_range = np.array(range(1,7,1))
tuned_parameters = [{'max_depth': n_range}]
tuned_parameters
```

```
Out[0]:
```

```
[{'max_depth': array([1, 2, 3, 4, 5, 6])}]
```

```
In [0]:
clf gs dt = GridSearchCV(DecisionTreeClassifier(random state=1), tuned parameters,
                          cv=5, scoring='accuracy')
clf_gs_dt.fit(X_train, Y_train)
Out[0]:
GridSearchCV(cv=5, error score='raise-deprecating'
       estimator=DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=None,
            max features=None, max leaf nodes=None,
            min_impurity_decrease=0.0, min_impurity_split=None,
            min_samples_leaf=1, min_samples_split=2,
            min weight fraction leaf=0.0, presort=False, random state=1,
            splitter='best'),
       fit params=None, iid='warn', n_jobs=None,
       param_grid=[{'max_depth': array([1, 2, 3, 4, 5, 6])}],
       pre_dispatch='2*n_jobs', refit=True, return_train_score='warn',
       scoring='accuracy', verbose=0)
In [0]:
clf_gs_dt.best_params_
Out[0]:
{'max_depth': 4}
In [0]:
plt.plot(n_range, clf_gs_dt.cv_results_['mean_test_score'])
Out[0]:
[<matplotlib.lines.Line2D at 0x7f3fe9368dd8>]
```



Сравнение моделей после подбора гиперпараметров

Стохастический градиентный спуск

In [0]:

```
sgd_optimized = SGDClassifier(l1_ratio=clf_gs_sgd.best_params_['l1_ratio']).fit(X_train, Y_train)
predicted_sgd_opt = sgd_optimized.predict(X_test)
```

```
In [0]:
accuracy_score(Y_test, predicted_sgd_opt)
Out[0]:
0.5409836065573771
In [0]:
balanced_accuracy_score(Y_test, predicted_sgd_opt)
Out[0]:
0.5338709677419355
In [0]:
(precision score(Y test, predicted sgd opt, average='weighted'),
recall_score(Y_test, predicted_sgd_opt, average='weighted'))
(0.6363244176013804, 0.5409836065573771)
In [0]:
f1_score(Y_test, predicted_sgd_opt, average='weighted')
Out[0]:
0.4332865784167616
Линейный классификатор на основе SVM
In [0]:
svm_optimized = LinearSVC(C=clf_gs_svm.best_params_['C']).fit(X_train, Y_train)
predicted_svm_opt = svm_optimized.predict(X_test)
In [0]:
accuracy_score(Y_test, predicted_svm_opt)
Out[0]:
0.6885245901639344
In [0]:
balanced accuracy score(Y test, predicted svm opt)
Out[0]:
0.6833333333333333
In [0]:
(precision_score(Y_test, predicted_svm_opt, average='weighted'),
recall_score(Y_test, predicted_svm_opt, average='weighted'))
Out[0]:
(0.8068852459016393, 0.6885245901639344)
In [0]:
```

f1 score(Y test, predicted svm opt, average='weighted')

Out[0]:

0.6528845252022647

Дерево решений

```
In [0]:
dt optimized = DecisionTreeClassifier(max depth=clf gs dt.best params ['max depth']).fit(X train, Y train)
predicted dt opt = dt optimized.predict(X test)
In [0]:
accuracy_score(Y_test, predicted_dt_opt)
Out[0]:
0.7704918032786885
In [0]:
balanced_accuracy_score(Y_test, predicted_dt_opt)
Out[0]:
0.7704301075268818
In [0]:
(precision_score(Y_test, predicted_dt_opt, average='weighted'),
recall_score(Y_test, predicted_dt_opt, average='weighted'))
Out[0]:
(0.7704918032786885, 0.7704918032786885)
In [0]:
f1 score(Y test, predicted dt opt, average='weighted')
```

Out[0]:

 $\tt 0.7704918032786885$

Подбор гиперпараметров позволил увеличить точность работы стохастического градиентного спуска и дерева решений. В случае с деревом решений, точность модели увеличилась существенно и после подбора гиперпараметров именно эта модель предоставляет наибольшую точность.